

Wstęp do uczenia maszynowego - Raport z projektu

Jan Skalski, gr.1

11 kwietnia 2025


1 O projekcie

Celem projektu było stworzenie modelu klasyfikacji o jak najlepszej jakości predykcyjnej na sztucznie zbudowanym zbiorze danych. W tym celu należało wykorzystać 2000 - elementowy zbiór treningowy z trzydziestoma zmiennymi oraz wektorem etykiet ze zbioru $\{-1, 1\}$. Dostępny był również 600 - elementowy zbiór testowy bez etykiet, na podstawie którego należało wyznaczyć wektor prawdopodobieństw przewidywanych etykiet i zwrócić go w celu porównania z rzeczywistym wektorem etykiet dla zbioru testowego. Jakość predykcyjną modelu badano przy użyciu zbalansowanej dokładności.

2 Przygotowanie danych

Na wstępie dostępne dane zostały sprawdzone pod względem ewentualnych braków i kolidujących typów zmiennych. Dane zarówno treningowe jak i testowe nie posiadały takowych i składały się jedynie ze zmiennych numerycznych. Z kolei wektor etykiet dla zbioru treningowego składający się z dwóch klas był idealnie zbalansowany w proporcji 1:1. Następnie prostym modelem regresji liniowej sprawdzono, że dane są silnie nieliniowe, co uwzględniono później przy wyborze modeli do testowania. W dalszej kolejności dane zostały przeskalowane do jednostkowej wariancji i zerowej średniej, przy czym dane testowe przeskalowano według rozkładu danych treningowych. W końcu przyjrano się poszczególnym zmiennym i ich wpływie na predykcję. W tym celu na zbiorze treningowym skorzystano z wbudowanej metody dla modelu lasu losowego *feature_importances*, która zwraca wskaźnik MDI (*mean decrease in impurity*) dla każdej zmiennej. Duża wartość tego wskaźnika sygnalizuje większą istotność danej zmiennej w predykcji. Dokładniej, wskazuje on na to jak dana zmienna łącznie wpływa na zmniejszenie entropii (lub indeksu Gini'ego) przy podziałach zbioru (rozgałęzieniach) w algorytmie drzewek decyzyjnych, z których składa się las losowy. Jeśli w pojedynczym drzewku spojrzymy jedynie na rozgałęzienia oparte na zmiennej, dla której ten wskaźnik jest względnie niski to zauważymy, że każde wspomniane rozgałęzienie nie obniża zbyt wiele entropii (nieuporządkowania) zbioru, co wskazuje, że dana zmienna jest mało przewidywalna i w istocie zbędna dla naszego przyszłego modelu. Tak prezentowały się uzyskane wskaźniki dla poszczególnych zmiennych:

Rysunek 1: Wykres istotności zmiennych w predykcji




Ponieważ wskaźnik MDI jest wielkością względną, więc powyższy wykres pozwala na bezpieczną interpretację, że z oryginalnie trzydziestu zmiennych tak naprawdę istotne w dalszej części będą jedynie zmienne 22-29, dla których wielkość tego wskaźnika wyraźnie jest 2-3 razy większa niż w przypadku zmiennych 0-21. Tak znacząca redukcja zmiennych umożliwiła dokładniejsze przyjrzenie się ich rozkładowi i relacjom między nimi. Wyznaczona zatem została macierz korelacji dla tych ośmiu zmiennych oraz dla każdej z nich zbadany za pomocą wykresu pudełkowego został rozkład na klasy $\{-1, 1\}$.

Tabela 1: Macierz korelacji zmiennych 22-29

-	22	23	24	25	26	27	28	29
22	1.0000	0.4782	0.0244	0.0264	-0.1225	0.0133	0.1577	-0.1303
23	0.4782	1.0000	0.3433	0.1474	-0.6856	0.3939	0.3815	-0.2463
24	0.0244	0.3433	1.0000	-0.0240	-0.5903	0.0120	-0.4428	-0.4861
25	0.0264	0.1474	-0.0240	1.0000	-0.6301	-0.0120	0.5630	-0.3370
26	-0.1225	-0.6856	-0.5903	-0.6301	1.0000	-0.3523	-0.2290	0.6467
27	0.0133	0.3939	0.0120	-0.0120	-0.3523	1.0000	-0.1991	-0.6618
28	0.1577	0.3815	-0.4428	0.5630	-0.2290	-0.1991	1.0000	0.4007
29	-0.1303	-0.2463	-0.4861	-0.3370	0.6467	-0.6618	0.4007	1.0000

Rysunek 2: Wykres rozkładu zmiennych 22-29 na klasy



Widać wówczas, że część zmiennych jest w pewnym stopniu skorelowana, co wykorzystano później przy budowie optymalnego modelu. Z kolei aby polepszyć zdolności predykcyjne przyszłego modelu, na podstawie wykresu rozkładu zmiennych do klas usunięto obserwacje odstające dla zmiennych 22, 23, 24, 26, 28 i 29, ponieważ dla nich wyraźnie zauważalna była tendencja przyporządkowania klasy.

3 Wybór modeli i parametrów do testowania

Po przetworzeniu danych przystąpiono do wyboru modeli i hiperparametrów w celu uzyskania optymalnego modelu. Mając na względzie mocną nieliniowość danych oraz ich numeryczność i zbalansowanie zdecydowano się na sprawdzenie trzech modeli: modelu wektorów podpierających z nieliniowym jądrem, lasu losowego i sieci neuronowej z nieliniową funkcją aktywacji (tangens hiperboliczny). Aby uniknąć przeuczenia zbiór treningowy podzielono na wtórny zbiór treningowy oraz zbiór walidacyjny w proporcji 7:3. Na zbiorze treningowym wtórnym przeprowadzono *tuningowanie* hiperparametrów dla wspomnianych modeli z użyciem metody GridSearchCV z warstwową 5-krotną krosvalidacją. Tak prezentowała się siatka hiperparametrów:

1. Model SVC wektorów podpierających:

- $C : \{0.1, 0.3, 0.5, 0.65, 0.8, 1, 1.2, 1.5, 2\}$
- $\text{kernel} : \{rbf, poly, sigmoid\}$
- $\text{gamma} : \{scale, auto, 1, 0.1, 0.01, 0.005, 0.001, 0.0001\}$

2. Model RFC lasu losowego:

- `n_estimators` : {50, 75, 100, 150, 200}
- `max_features` : {`sqrt`, `log2`}
- `max_depth` : {5, 10, 15, 20, `None`}
- `max_leaf_nodes` : {100, 125, 150, 175, 200}
- `min_samples_leaf` : {1, 2, 3, 4}
- `min_samples_split` : {2, 3, 4, 5}
- `min_impurity_decrease` : {0.01, 0.001, 0.0001}

3. Model MLPC sieci neuronowej:

- `hidden_layer_sizes` : {(50,), (20, 20), (30, 10), (10, 30), (10, 10, 10)}
- `solver` : {`sgd`, `adam`}
- `alpha` : { 0.1, 0.12, 0.15, 0.18, 0.2}

4 Optymalne hiperparametry

Metoda *GridSearchCV* zwróciła następujące optymalne hiperparametry na zbiorze treningowym wtórnym dla każdego z wymienionych wcześniej modeli:

1. Model SVC wektorów podpierających:

- `C` = 0.65
- `kernel` = `rbf`
- `gamma` = 1

2. Model RFC lasu losowego:

- `n_estimators` = 150
- `max_features` = `sqrt`
- `max_depth` = 20
- `max_leaf_nodes` = 175
- `min_samples_leaf` = 1
- `min_samples_split` = 2
- `min_impurity_decrease` = 0.0001

3. Model MLPC sieci neuronowej:

- `hidden_layer_sizes` = (20, 20)
- `solver` = `adam`
- `alpha` = 0.18

5 Wyniki na zbiorze treningowym i walidacyjnym


Po znalezieniu optymalnych hiperparametrów dla wspomnianych modeli, sprawdzono ich działanie na zbiorze walidacyjnym i porównano z wynikami na zbiorze treningowym, aby sprawdzić czy modele nie były przeuczone. Ponadto dla trzech wspomnianych optymalnych modeli zbudowano również komitet modeli *VotingClassifier*, który z parametrem `voting = soft` działa następująco: sumuje prawdopodobieństwa przynależności do klas zwracane przez poszczególne modele, dzieli uzyskane wyniki przez liczbę modeli, na których bazuje i ostatecznie wybiera tę klasę, dla której takie średnie prawdopodobieństwo jest większe. Tak wygląda tabela wyników dla optymalnych modeli oraz komitetu *Voting*:

Tabela 2: Zbalansowana dokładność na zbiorze treningowym i walidacyjnym

Rodzaj modelu	Zbiór treningowy	Zbiór walidacyjny
SVC	0.91453	0.95272
RandomForestClassifier	0.87030	0.89082
MLPClassifier	0.87992	0.90013
VotingClassifier	0.97557	0.94046

Zatem jako model z największą zbalansowaną dokładnością na zbiorze walidacyjnym został wybrany model wektorów podpierających z parametrami jak w części 4. Wykresy krzywych ROC i macierz pomyłek dla tego modelu prezentują się następująco:

Rysunek 3: Wykresy krzywych ROC dla modelu SVC



Macierz pomyłek dla modelu *SVC* wektorów podpierających na zbiorze walidacyjnym: $\begin{bmatrix} 275 & 16 \\ 11 & 267 \end{bmatrix}$

6 Podsumowanie

Po przeanalizowaniu i przeskalowaniu danych, w celu zwiększenia jakości i wydajności modelu zostały zredukowane mało istotne zmienne oraz obserwacje odstające. Na zbiorze treningowym wtórnym przeprowadzono *tuning* hiperparametrów dla trzech wybranych modeli nieliniowych. Dla optymalnych modeli utworzono komitet *VotingClassifier* i zbadano zbalansowaną dokładność dla tych czterech modeli na zbiorze walidacyjnym, na podstawie czego wybrano najlepszy model. Okazał się nim model wektorów podpierających z parametrami: $C = 0.65$, $kernel = rbf$, $gamma = 1$. Dał on najwyższy wynik zbalansowanej dokładności na zbiorze walidacyjnym, równy 0.95272. Ponadto wynik ten był lepszy niż na zbiorze treningowym co wskazuje, że model nie był przeuczony oraz daje przesłanki, że wynik na zbiorze testowym również nie będzie gorszy od wyniku na zbiorze uczącym. Aby wyznaczyć wektor prawdopodobieństw przynależności do klas na zbiorze testowym, model ten został nauczony na oryginalnym zbiorze treningowym (zbiorze treningowym wtórnym razem z walidacyjnym).