

Wstęp do uczenia maszynowego - Raport z pracy domowej 3

Jan Skalski, gr.1

11 kwietnia 2025

1 Część 1

1.1 Ogólny opis metody

Celem pierwszej części pracy domowej było przygotowanie metody *knn*, opierającej się na algorytmie k-najbliższych sąsiadów. Metoda ta przyjmowała następujące argumenty:

1. macierz rzeczywistą X typu $n \times r$, reprezentującą n punktów w $\mathbb{R}^r$ (zbiór treningowy),
2. n -elementowy wektor y odpowiadający etykiетom obserwacji ze zbioru treningowego X
3. macierz rzeczywistą Z typu $m \times p$, reprezentującą m punktów w $\mathbb{R}^p$ (zbiór testowy),
4. liczbę całkowitą $1 \leq k \leq n$, oznaczającą liczbę najbliższych sąsiadów biorących udział w poszukiwaniu etykiety odpowiadającej punktom ze zbioru testowego,
5. wartość rzeczywistą $p \geq 1$, domyślnie równą 2, określającą, która metryka Minkowskiego L_p będzie używana do poszukiwania najbliższych sąsiadów. Dopuszczalne również było, by $p = \infty$.

Metoda zwracała:

1. m -elementowy wektor w przewidywanych etykiет dla obserwacji ze zbioru testowego Z ,
2. macierz P typu $m \times s$ prawdopodobieństw przyporządkowania konkretnej etykiety dla różnych obserwacji, gdzie s było liczbą unikatowych etykiет w y .

1.2 Działanie metody

Metoda *knn* na wejściu sprawdzała poprawność przekazywanych argumentów, a następnie ujednoliciła ich strukturę. Macierze X i Z - do typu *array* dwuwymiarowy a y - do typu *array* jednowymiarowy. Następnie macierze X i Z były standaryzowane na podstawie rozkładu X , aby zmienne o dużych średnich wartościach nie wpływały zbyt na odległości między obserwacjami. Po sprawdzeniu i przygotowaniu danych metoda wyznaczała dla i -tej obserwacji z Z wektor k -elementowy indeksów obserwacji z X o najmniejszych odległościach od niej. Odległości badano przy użyciu pomocniczej funkcji *mink dist*, która przyjmowała dwa wektory x i y tej samej długości oraz parametr p odpowiedzialny za rodzaj metryki Minkowskiego zastosowanej przy liczeniu odległości. Dla $p \geq 1$ była to metryka:

$$d(x, y) = \left(\sum_{i=1}^r |x_i - y_i|^p \right)^{\frac{1}{p}},$$

a dla $p = \infty$:

$$d(x, y) = \max_{i \in [r]} |x_i - y_i|.$$

Dalej dla tego wektora indeksów wyznaczany był odpowiadający mu wektor y_k etykiет z y , po czym za przewidywaną etykiетę dla i -tej obserwacji z Z brano modę z tego wektora lub, gdy nie była ona jednoznaczna losowano z rozkładu jednostajnego z podwektora najczęściej występujących etykiет w wektorze y_k , po czym otrzymaną wartość wstawiano do w_i . Równolegle, dla każdej unikatowej etykiety z y_k liczone było jak często występuje ona w tym wektorze, po czym liczby te dzielone były przez k i trafiały do wierszy macierzy P . Gdy któraś z unikatowych etykiет z y nie pojawiała się w wektorze y_k , to do macierzy P wstawiane było w odpowiednim miejscu 0. W ten sposób na kolejnych miejscach w i -tym wierszu macierzy P znalazły się prawdopodobieństwa z jakimi należało, by przyporządkować kolejne unikalne etykiety dla i -tej obserwacji z Z .

2 Część 2

2.1 Testowanie poprawności metody

Do testowania poprawności i później efektywności opisanej wyżej metody wygenerowano trzy losowe zbiory treningowe z $\mathbb{R}^2$ oraz losowe wektory etykiет dla nich:


1. zbiór X_1 o 200 elementach z przedziału $(0, 1)^2$,
2. zbiór X_2 o 500 elementach losowych z rozkładu jednostajnego na $[-100, 100]^2$,
3. zbiór X_3 o 1000 elementach, które w pierwszej kolumnie pochodzą z rozkładu jednostajnego na $[-0.1, 0.1]$, a w drugiej z rozkładu jednostajnego na $[-1000, 1000]$.

Dla zbioru X_1 wektor etykiet y_1 był binarny, dla zbioru X_2 wektor y_2 składał się z liczb 0, 1, 2, 3, a dla X_3 , wektor y_3 z liczb 0, 1, 2, 3, 4, 5, 6, 7. Zbiory testowe Z_1, Z_2, Z_3 pochodziły z tych samych rozkładów, co odpowiadające im zbiory treningowe, lecz co do wielkości były 5 razy mniejsze. Aby sprawdzić, czy metoda knn działa poprawnie dla każdego z powyższych zbiorów treningowych i odpowiadających im etykiet oraz dla różnych $p \in \{1, \frac{3}{2}, 5, 10, \infty\}$, wyznaczono wektory przewidywanych etykiet dla zbiorów testowych tożsamy z treningowymi przy użyciu metody z parametrem $k = 1$. Wyniki w każdym przypadku pokrywały się z wektorami etykiet dla zbiorów treningowych.

2.2 Porównanie z działaniem modelu KNeighborsClassifier

W celu zbadania, czy metoda knn i model KNeighborsClassifier działają w zbliżony sposób, sprawdzono na tych samych danych treningowych i testowych, czy wektory przewidywanych etykiet dla zbiorów testowych są takie same dla metody i wspomnianego modelu. Zależność zbadano także pod względem parametru k i p (w przypadku $p = \infty$ dla modelu KNeighborsClassifier zdefiniowano metrykę $mink\ inf\ dist\ (L_\infty)$, gdyż nie jest ona dostępna w wyborze parametrów modelu). Wyniki tego porównania dla trzech wspomnianych wcześniej zbiorów przedstawiono na trzech wykresach. Każdy pokazywał słupki frakcji tak samo przewidzianych etykiet w zależności od $p \in \{1, 2, \infty\}$ oraz k (oś pozioma) dobranych proporcjonalnie do rozmiaru zbiorów.

Rysunek 1: Wykresy frakcji tak samo przewidzianych etykiet przez metodę knn i model KNeighborsClassifier




Wykresy te pokazują, że niezależnie od wielkości zbiorów metoda i model przewidują bardzo podobnie dla małych oraz dla stosunkowo dużych k , natomiast największe różnice można zaobserwować dla k równych około $\frac{1}{10}$ wielkości zbiorów testowych.

2.3 Testowanie czasu działania metody

Czas działania metody *knn* został sprawdzony w zależności od wielkości zbiorów treningowych (testowane były X_1, X_2, X_3 wraz z odpowiadającymi im wektorami etykiet i zbiorami testowymi), parametru k dobranego w zależności od wielkości zbiorów oraz parametru $p \in \{1, 2, \infty\}$.

Rysunek 2: Wykresy czasów działania metody *knn* dla różnych zbiorów w zależności od parametru k i p



Powyższe wykresy wskazują, że czas wykonywania metody praktycznie nie zależy od parametru k , natomiast rośnie dość wyraźnie wraz ze zwiększaniem wielkości zbioru, co wydaje się dość naturalne. Z kolei widoczne jest także, że metoda działa najszybciej przy użyciu metryki Minkowskiego L_∞ .

3 Część 3

3.1 Testowanie metody na prawdziwych danych

W tej części został wykorzystany 768-elementowy zbiór danych *pima*, dotyczący pacjentów podejrzanych o pewną chorobę. Zmiennych objaśniających było 8 i dotyczyły one cech i parametrów medycznych pacjentów. Zmienna przewidywana była binarna i wskazywała na istnienie choroby. Zbiór ten został podzielony na zbiór treningowy, walidacyjny i testowy w proporcji odpowiednio 5:2:3. Metoda *knn* testowana była w odniesieniu do modelu *KNeighborsClassifier*. Dla obu powyższych wyznaczone zostały optymalne parametry k ze zbioru $\{1, 2, 3, 4, 5, 7, 10, 15, 20, 25, 30, 40, 50, 75, 100, 125, 150, 200\}$ pod względem dokładności na zbiorze walidacyjnym, w zależności od parametru $p \in \{1, 2, \infty\}$. Następnie dla tych optymalnych parametrów k wyznaczone zostały miary dokładności, precyzji, czułości, $f1$ oraz AUC na zbiorze testowym zarówno dla metody *knn*, jak i dla modelu *KNeighborsClassifier*, przy czym jako zbiór treningowy wykorzystano tym razem treningowy wraz z walidacyjnym. Ponadto wy-

korzystając macierz prawdopodobieństw P zwracaną przez metodę knn wyznaczono także krzywe ROC w każdym z przypadków i ostatecznie wyliczone zostały również macierze pomyłek. Tak prezentują się otrzymane wyniki:

Tabela 1: Miary dla $p = 1$

-	knn method	KNC model
optimal k	30	40
accuracy	0.8095	0.7706
recall	0.5479	0.3699
precision	0.7843	0.7941
f1	0.6452	0.5047
AUC	0.8478	0.8460

Tabela 2: Miary dla $p = 2$

-	knn method	KNC model
optimal k	20	40
accuracy	0.7965	0.8052
recall	0.5342	0.4932
precision	0.7500	0.8182
f1	0.6240	0.6154
AUC	0.8302	0.8324

Tabela 3: Miary dla $p = \infty$

-	knn method	KNC model
optimal k	20	25
accuracy	0.7835	0.7619
recall	0.5068	0.3973
precision	0.7255	0.7250
f1	0.5968	0.5133
AUC	0.8000	0.7888

Macierze pomyłek dla $p = 1$:

- Dla metody knn : $\begin{bmatrix} 147 & 11 \\ 33 & 40 \end{bmatrix}$
- Dla modelu KNC : $\begin{bmatrix} 151 & 7 \\ 46 & 27 \end{bmatrix}$


Macierze pomyłek dla $p = 2$:

- Dla metody knn : $\begin{bmatrix} 145 & 13 \\ 34 & 39 \end{bmatrix}$
- Dla modelu KNC : $\begin{bmatrix} 150 & 8 \\ 37 & 36 \end{bmatrix}$

Macierze pomyłek dla $p = \infty$:

- Dla metody knn : $\begin{bmatrix} 144 & 14 \\ 36 & 37 \end{bmatrix}$
- Dla modelu KNC : $\begin{bmatrix} 151 & 7 \\ 44 & 29 \end{bmatrix}$

Rysunek 3: Wykresy krzywych ROC dla metody knn oraz modelu KNC w zależności od parametru p



3.2 Wnioski

Wartości miar i wykresy krzywych ROC pokazują, że stworzona metoda knn działa na podobnym poziomie jakości jak model $KNeighborsClassifier$ z dostosowanym jedynie parametrem k . Ponadto dokładność i AUC są nawet nieco wyższe dla metody knn . Z kolei widoczny dość wyraźnie dla metody, jak i modelu jest niski poziom miary czułości na zbiorze testowym. Może to wynikać z niezbalansowania klas w zbiorze testowym, gdyż stosunek występowania klasy negatywnej do pozytywnej wynosi około 3:7. Jeśli natomiast chodzi o wpływ parametru p (określającego rodzaj metryki Minkowskiego w liczeniu odległości między obserwacjami) na jakość predykcji to zauważalnie najlepsze miary zostały uzyskane dla $p = 1$.

4 Podsumowanie

Analiza poprzednich części wskazuje, że zaimplementowana metoda działa prawidłowo, porównywalnie jak model najbliższych sąsiadów bez ulepszonych hiperparametrów. Na niewielkich zbiorach wykonuje się sprawnie i daje dobre własności predykcyjne, co również dzięki prostocie jej implementacji i podatności na udoskonalenia czyni ją poprawną i efektywną.