

Wstęp do uczenia maszynowego - Raport z pracy domowej 2

Jan Skalski, gr.1

11 kwietnia 2025

1 Część 1

1.1 Przygotowanie danych

Pierwsza część pracy domowej polegała na przygotowaniu trzech jak najlepszych modeli regresji logistycznej, kolejno bez regularyzacji, z regularyzacją L1 i L2. W regularyzacji L1 do minimalizowania funkcji celu *kwadratów różnic* dodaje się bezwzględną funkcję straty współczynników. Natomiast w regularyzacji L2 funkcja straty jest kwadratowa. W istocie przejawia się to następującymi zależnościami: regularyzacja L1 powoduje, że współczynniki przy najmniej istotnych dla predykcji zmiennych są ściągane do zera, a w regularyzacji L2 wszystkie współczynniki są co do wartości bezwzględnej małe, lecz niezerowe. Dane, dla których przygotowano modele pochodziły z banku i dotyczyły zdolności kredytowej tysiąca klientów. Reprezentowała ją zmienna binarna *class*. Na wstępie nieco zmodyfikowano strukturę danych, zamieniając wartości zmiennych z wewnętrznym porządkiem na kolejne liczby naturalne. Z kolei nominalne zmienne przekształcono funkcją *get dummies*, która tworzy nowe zmienne zero-jedynkowe na podstawie unikatowych wartości. Po zmodyfikowaniu struktury, dane podzielono na zbiór treningowy i testowy w proporcji 7:3. W celu zwiększenia zdolności predykcyjnej optymalnych modeli i zminimalizowania czasu ich poszukiwania dane zostały następnie ustandaryzowane do zerowej średniej i jednostkowej wariancji (aby model nie faworyzował zmiennych o dużych wartościach w predykcji klasy).

1.2 Optymalne modele

Po takim przygotowaniu danych, optymalnych modeli szukano metodą *GridSearchCV*, która testuje wszystkie kombinacje z dostarczonej siatki hiperparametrów pod kątem miary dokładności modelu na danych treningowych. Wspomniana funkcja w swojej procedurze korzystała z powtarzanej 10-krotnej krosvalidacji aby znaleźć model z najlepszymi zdolnościami predykcyjnymi. Badano hiperparametry:

- *C* (jedynie dla modeli z regularyzacją): odwrotnie proporcjonalnie koryguje siłę regularyzacji
- *solver* : algorytm używany w procesie konstruowania modelu


Otrzymano następujące wyniki dla modelu:

- bez regularyzacji: *solver* = ***newton – cg***
- z regularyzacją L1: *C* = **1**, *solver* = ***liblinear***
- z regularyzacją L2: *C* = **5**, *solver* = ***liblinear***

Powyższe modele posiadały następujące własności predykcyjne:

Score	No regularisation		L1 regularisation		L2 regularisation	
	Train set	Test set	Train set	Test set	Train set	Test set
accuracy	0.7900	0.7733	0.7900	0.7700	0.7900	0.7700
recall	0.8912	0.8514	0.8975	0.8514	0.8912	0.851400
precision	0.8177	0.8438	0.8140	0.8400	0.8177	0.840000
f1	0.8529	0.8475	0.8537	0.8456	0.8529	0.8456
AUC	0.8298	0.7903	0.8300	0.7922	0.8298	0.7898

Rysunek 1: Wykresy krzywych ROC dla różnych modeli




Macierz pomyłek dla modelu z regularyzacją L2 na zbiorze testowym: $\begin{bmatrix} 55 & 40 \\ 26 & 162 \end{bmatrix}$

1.3 Analiza współczynników

Dzięki temu, że dane zostały uprzednio ustandaryzowane, bezwzględną wielkość poszczególnych współczynników w modelu regresji logistycznej można interpretować jako poziom istotności i wpływu odpowiadających im zmiennych na przewidywaną klasę. W szczególności w modelu z regularyzacją L1 współczynniki zerowe oznaczały, że dana zmienna ma bardzo znikomy, jak nie zerowy wpływ w procesie predykcji, przez co staje się zbędna i może powodować nadmierne przeuczenie modelu. Wpływ każdej zmiennej ukazuje następujący wykres:

Rysunek 2: Bezwzględna wielkość współczynników dla różnych zmiennych w optymalnych modelach



1.4 Wnioski

Powyższe wykresy i tabela wskazują, że optymalne modele dobrze działają na zbiorze testowym dając zbliżone wyniki jak na treningowym. Podobne wielkości miar można zaobserwować także pomiędzy kolejnymi modelami, co pokazuje, że na naszym zbiorze danych regularyzacja praktycznie nie wpływa na polepszenie zdolności predykcyjnych modelu. Może to być oznaka nieliniowości danych lub ich niedoboru. Macierz pomyłek dla modelu z regularyzacją L2 na zbiorze testowym nasuwa wniosek, że model około 6 razy częściej popełnia błąd przyporządkowania klasy negatywnej kiedy w istocie jest pozytywna niż na odwrót. Mając jednak na uwadze że funkcja kosztu dla tych danych kara 5 razy bardziej za błąd przyporządkowania klasy pozytywnej, gdy w istocie jest negatywna, jest to jak najbardziej akceptowalny wynik. Wykres współczynników w modelu z regularyzacją L1 pozwala z kolei na selekcję zmiennych, o czym będzie jeszcze w części drugiej.


2 Część 2

2.1 Redukcja danych

Na podstawie wyników i wniosków z części pierwszej w celu poszukiwania optymalnego modelu wektorów podpierających o lepszych własnościach, dane zostały uprzednio zredukowane. Ograniczenie danych miało miejsce w dwóch płaszczyznach i oczywiście opierało się na badaniu danych nieustandaryzowanych. Na podstawie wykresu współczynników w modelu regresji

logistycznej z regularyzacją L2 usunięto zmienne, dla których wartość bezwzględna współczynnika nie przekraczała **0.03**. Z kolei na podstawie wszystkich trzech wykresów współczynników zbadano rozkład na klasy zmiennych numerycznych, które miały w każdym modelu stosunkowo duży wpływ na predykcję. Zrobiono to na zbiorze treningowym w celu znalezienia obserwacji odstających.

Rysunek 3: Rozkład na klasy zmiennych numerycznych: wielkość kredytu, wiek i długość spłaty (w miesiącach) na zbiorze treningowym



Powyższe wykresy wskazują, że większe prawdopodobieństwo na przyporządkowanie pozytywnej klasy (przyznanie kredytu) mają ludzie ubiegający się o niewysoki kredyt na krótki okres, w wieku między 30 a 40 lat. Jednakże na tych wykresach można także zauważyć obserwacje odstające, tzn. między innymi takie, których wielkość kredytu, czy długość spłaty jest bardzo duża, a i tak przyznana klasa jest pozytywna. Takie skrajne obserwacje mogą z reguły prowadzić do nadmiernych błędów modelu w poprawnej predykcji, dlatego część z nich została usunięta z obu zbiorów treningowego i testowego. Po dokonaniu redukcji zmiennych i obserwacji na obu zbiorach, zostały one ponownie ustandaryzowane.

2.2 Optymalny model

Podobnie jak w części pierwszej optymalny model wektorów podpierających był szukany metodą *GridSearchCV* spośród hiperparametrów:

- **C** : odpowiada za siłę regularyzacji
- **kernel**: odpowiada za rodzaj funkcji używanej w równaniu hiperpowierzchni rozgraniczającej klasy
- **gamma**: współczynnik we wspomnianej funkcji

Najlepszą dokładność na zredukowanych danych treningowych uzyskano dla modelu o parametrach: **C** = 10, **kernel** = *rbf* i **gamma** = 0.01. Tak prezentują się cechy predykcyjne tego modelu:


Tabela 1: Tabela miar

Score	Train set	Test set
accuracy	0.8379	0.8375
recall	0.9187	0.9362
precision	0.8566	0.8381
f1	0.8865	0.8844
AUC	0.8977	0.9046

Macierz pomyłek na zbiorze testowym:

61	34
12	176

ROC curves for best SVM model (C = 10, gamma = 0.01, kernel = 'rbf')



3 Podsumowanie

Analiza optymalnych modeli w części pierwszej pozwoliła na odpowiednią selekcję danych, dzięki czemu w części drugiej optymalny model wektorów podpierających uzyskał dużo lepsze własności predykcyjne na zbiorze testowym.