

Wstęp do uczenia maszynowego - Raport z pracy domowej 4


Jan Skalski, gr.1

11 kwietnia 2025

1 Wstęp

Celem czwartej pracy domowej było zbadanie działania różnych algorytmów *clustering'u* na czterech specyficznych zbiorach danych:

Wizualizacja danych wraz z rozkładem na klasy



Testowanymi algorytmami były:

1. K-Means - wymaga podania liczby klastrów na wejściu, następnie losuje właśnie tyle punktów (centroidów) i każdą obserwację przyporządkowuje do centroidu, do którego ma ona najbliższą według metryki L_2 . Zbiór obserwacji przyporządkowanych do konkretnego centroidu określa się jako pojedynczy klastre. Następnie klastry są aktualizowane poprzez wyznaczenie nowych centroidów jako średnich wewnątrz klastra. Takie iteracyjne działanie kończy się, gdy spełnione zostaną kryteria stopu, np. przyporządkowanie tych samych obserwacji do klastrów po zmianie centroidów, co w poprzedniej iteracji.
2. AgglomerativeClustering - jest to algorytm hierarchiczny, tzn. zaczyna od małych klastrów i łączy je w większe na podstawie podobieństw między klastrami. Podanie liczby klastrów na wejściu jest opcjonalne. Algorytm zaczyna od potraktowania każdej obserwacji jako pojedynczy klastre, a następnie łączy w jeden klastre te, które są najbliższe sobie według określonej w parametrze *linkage* funkcji:
 - *single* - min. po obserwacjach w klastrach z odległości euklidesowej między nimi
 - *complete* - max. po obserwacjach w klastrach z odległości euklidesowej między nimi
 - *average* - suma odległości euklidesowych między obserwacjami w jednym klastrze, a drugim podzielona przez liczbę obserwacji w obu klastrach
 - *ward* - minimalizowanie wariancji obserwacji w połączonym klastrze

Łączenie trwa do momentu, gdy liczba klastrów będzie równa tej podanej na wejściu lub gdy zostanie spełnione kryterium stopu, tj. odległość między dwoma klastrami będzie większa od określonego jako parametr *distance_threshold* progu.

3. DBSCAN - jest to algorytm nie wymagający liczby klastrów na wejściu. Jego działanie przebiega następująco: wybiera losowo obserwację i sprawdza, czy w jej epsilon-otoczeniu (epsilon podawany jako parametr) znajduje się co najmniej pewna liczba obserwacji, którą określa się na wejściu. Jeśli tak, obserwacja ta traktowana jest jako punkt centralny i dla jego otoczenia badane jest łańcuchowo, które obserwacje to także punkty centralne. W ten sposób to otoczenie jest rozszerzane do momentu aż dla zewnętrznych punktów nie będzie istniało odpowiednie otoczenie, więc nie będą to punkty centralne, co za tym idzie maksymalne otoczenie będzie pojedynczym klastrze. Następnie algorytm losuje punkt z poza tego klastra i przeprowadza analogiczne działanie w celu wyznaczenia następnych klastrów. Algorytm wyróżnia się tym, że wyłącza obserwacje odstające, gdyż są to punkty, które nie trafiają do żadnego klastra i nie będą punktami centralnymi.

2 Pytanie badawcze 1


Które algorytmy wymagają liczby klastrow na wejściu? Jak wybór tego parametru wpływa na wyniki?

Na pierwszą część tego pytania odpowiedź została już udzielona w opisie algorytmów. Pozostaje sprawdzić wpływ liczby klastrow podawanej na wejściu na wyniki algorytmów, które jej wymagają lub jest ona opcjonalna, tj. K-Means oraz Agglomerative Clustering. Ograniczono się do liczby klastrow ze zbioru $\{2, 3, 4, 5\}$, gdyż patrząc na wizualizacje dostępnych danych większa liczba klastrow wydawała się przesadzona.

2.1 Wpływ liczby klastrow na działanie algorytmu K-Means

Tak prezentują się wizualizacje klastrowania metodą K-Means dla różnej liczby klastrow dla każdego ze zbiorów (krzyżykami oznaczono centroidy):

Wizualizacja działania K-Means w zależności od liczby klastrow



Z powyższych wykresów widać, że metoda K-Means daje poprawne grupowanie tak naprawdę tylko dla danych 1 dla 3 klastrow. Jest tak, bo w tym zbiorze danych podobieństwo klas opiera się jedynie na odległości euklidesowej, a dla metody K-Means jest ona podstawą budowania klastrow. Ponadto dla każdego zbioru danych zbadano miarę SSE, która jest sumą po klastrach zsumowanych odległości w klastrze od odpowiadającego mu centroidu i w tabeli przedstawiono jak ta miara zależy od liczby klastrow:


Tabela 1: Miara SSE w zależności od liczby klastrow

-	2 clusters	3 clusters	4 clusters	5 clusters
Data 1	312.842	42.899	36.151	29.749
Data 2	598.502	360.575	254.563	200.365
Data 3	604.191	403.830	261.168	197.820
Data 4	155.281	97.862	62.412	51.930


2.2 Wpływ liczby klastrow na działanie AgglomerativeClustering



Dla tego algorytmu wpływ liczby klastrow zbadano dodatkowo w zależności od funkcji przekazywanej jako *linkage* określającej jak badać podobieństwo między klastrami. Wykresy utworzono oddzielnie dla każdego zbioru danych:

Wizualizacja działania AgglomerativeClustering w zależności od liczby klastrow i funkcji *linkage* dla danych numer 1




Wizualizacja działania AgglomerativeClustering w zależności od liczby klastrow i funkcji *linkage* dla danych numer 2





Analizując powyższe wykresy widać, że najbardziej dopasowane wyniki dla wszystkich zbiorów danych dawała metoda z parametrem *linkage* ustawionym na *single*. Jeśli chodzi o liczbę klastrow, to dla danych numer 1 było to 3, dla danych numer 2 i 3 było to 2 a ostatni zbiór danych w oczywisty sposób nie posiadał żadnych podobieństw między obserwacjami, więc większe od 1 liczby klastrow powodowały dość losowe, choć ciekawe wyniki. Ponadto dla różnych funkcji *linkage* dla każdego ze zbioru danych stworzono także dendrogramy, aby zobaczyć od innej strony jak różne funkcje wpływają na łączenie klastrow.

Dendrograms w zależności od funkcji podobieństwa *linkage*




Potwierdzają one, że funkcja podobieństwa *single* dawała najlepsze grupowanie na tych zbiorach danych.

3 Pytanie badawcze 2

Zbadaj wpływ parametru szumu (*noise*) dla zestawów danych 2 i 3.

Parametr szumu dla zbiorów 2 i 3 wpływał na wariancję danych i im większy, tym bardziej rozrzucone były obserwacje, tym samym obniżając odseparowanie klas. Zbadano jak poradzą sobie wszystkie omówione w punkcie 1 algorytmy w zależności od wartości szumu. Wpierw zbadano wartość SSE dla K-Means w zależności od szumu i liczby klastrów:


SSE w zależności od wartości szumu i liczby klastrów



Powyższe wykresy wskazują, że niezależnie od liczby klastrów przyrost SSE wraz ze zwiększaniem zaszumienia danych jest dość zbliżony.

Dalej skupiono się na algorytmie DBSCAN i w celu znalezienia optymalnej wartości parametru *epsilon* dla tego algorytmu, sprawdzono jego działanie na każdym zbiorze danych w zależności od kilku wartości *epsilon*:


Wyniki działania DBSCAN w zależności od wartości parametru *epsilon*




Widać, więc że najdokładniejsze grupowanie z rozsądną liczbą obserwacji zaklasyfikowanych jako odstające, daje algorytm z parametrem *epsilon* równym 0.1. Zatem tę wartość wykorzystano przy badaniu wpływu szumu.

W końcu zwizualizowano wyniki działania K-Means, AgglomerativeClustering (z liczbą klastrów równą 2, przyjętą za optymalną) oraz DBSCAN (z *epsilon* równym 0.1) w zależności od wartości szumu ze zbioru {0.03, 0.06, 0.09, 0.12} (w poprzednich punktach wartość szumu dla danych 2 i 3 wynosiła 0.05):

Wpływ szumu na działanie różnych algorytmów na danych numer 2



Wpływ szumu na działanie różnych algorytmów na danych numer 3




Wykresy wskazują zatem, że najlepiej z zaszumionymi danymi radzi sobie algorytm DBSCAN, który dodatkowo znajduje obserwacje odstające, a takowych w przypadku mocno zaszumionych danych jest więcej i są ciężiej wykrywalne.

4 Pytanie badawcze 3

Wygeneruj wykres pokazujący, jak całkowita suma odległości między punktami w klastrach zależy od liczby klastrów.

Sumowano euklidesowe odległości pomiędzy dowolnymi dwoma punktami w klastrze po czym zsumowano uzyskane sumy po wszystkich klastrach. Wykres takowych sum został wygenerowany dla K-Means oraz AgglomerativeClustering (dla *linkage* ustawionym na *single* lub *average*) w zależności od liczby klastrów od 2 do 15 dla każdego ze zbiorów danych. Przerywaną linią oznaczono opisaną wcześniej sumę liczoną dla prawdziwych klas w konkretnych danych.

Całkowita suma odległości obserwacji w klastrach od liczby klastrów



Wykresy wskazują na dość oczywistą zależność, że wraz ze zwiększaniem liczby klastrów całkowita suma odległości w klastrach bardzo mocno maleje. Co ciekawsze pokazują również jak dobrze grupuje algorytm AgglomerativeClustering z parametrem *linkage* ustawionym na *single*. Badana suma dla niego pokrywa się praktycznie z sumą dla prawdziwych klas we wszystkich danych i niezależnie od określonej na wejściu liczby klastrów.

5 Podsumowanie

Przeprowadzone analizy różnych zależności w celu odpowiedzi na postawione pytania badawcze nasuwają wniosek, że pożądane działanie różnych algorytmów klastrowych wiąże się z postacią danych, którymi dysponujemy. Algorytm K-Means będzie działał najlepiej na danych separowalnych w euklidesowym znaczeniu, z kolei DBSCAN czy grupowanie hierarchiczne sprawdzą się lepiej dla danych o nietypowym rozkładzie.