

Wstęp do uczenia maszynowego - Raport z pracy domowej 1

Jan Skalski, gr.1

11 kwietnia 2025


1 O eksperymencie

Przeprowadzony eksperyment miał na celu zbadanie wpływu parametrów:

- kryterium podziału (*gini* lub *entropy*)
- maksymalna głębokość drzewa
- minimalna liczba obserwacji w liściu,

na dokładność drzewa decyzyjnego opartego na danym modelu. Załączone dane należało podzielić w proporcji 7:3 na zbiór treningowy i testowy i następnie przeprowadzić krosvalidację na zbiorze treningowym sprawdzając tym samym miarę dokładności drzewa przy określonych parametrach. Aby otrzymać możliwie najdokładniejszy efekt wspomniana miara była testowana w zależności od wszystkich kombinacji powyższych parametrów. Z powodu dużej liczby kombinacji do sprawdzenia ograniczone do minimum zostało wielokrotne przeprowadzanie krosvalidacji dla tego samego modelu. Natomiast została zwiększona liczba podzbiorów, na które dzielony jest wyjściowy zbiór w tym procesie z domyślnych pięciu do dziesięciu. Wyniki zostały przedstawione na 4 wykresach typu *heatmap*, dwa badające średnią miarę pojedynczej krosvalidacji dla obu kryteriów podziału i dwa pokazujące jej odchylenie standardowe również dla obu kryteriów. Na wykresach zostały zaznaczone interesujące nas eksrema, to znaczy dla średniej miary wartość największa, a dla odchylenia standardowego najmniejsza, dzięki czemu można łatwo odczytać optymalne w naszym przypadku parametry modelu.

Rysunek 1: Uzyskane wykresy



2 Wnioski

Z wykresów można odczytać następujące zależności:

- średnia miara dokładności drzewa praktycznie nie zależy od minimalnej liczby obserwacji w liściu
- średnia dokładność zależy od głębokości drzewa, gdy wartości te są mniejsze od około 10, dla większych głębokości średnia dokładność jest zbliżona
- kryterium podziału nieznacznie wpływa na średnia dokładność
- najmniej rozrzucone wartości dokładności drzewa występują dla większych wartości parametrów głębokości i minimalnej liczby obserwacji w liściu
- Stosunkowo mniejsze odchylenie standardowe można zaobserwować dla kryterium podziału *gini*

Po przeanalizowaniu powyższych wykresów, jako jeden z najbardziej optymalnych modeli wybrano kryterium podziału *gini* i parametry głębokości oraz minimalnej liczby obserwacji w liściu równe 13. Aby uzasadnić ten wybór wyznaczono parametr *ccp alpha*, dla którego wartość średniej dokładności jest największa (korzystając z 10 - stopniowej krosvalidacji). Parametr ten odpowiada za przycinanie drzewa w taki sposób by minimalizować jego koszt i złożoność, co jednocześnie poprawia dokładność. Wówczas porównano średnią dokładność i odchylenie standardowe wybranego modelu do najlepszych średniej i odchylenia uzyskanych po przycinaniu drzewa (wszystkie wielkości liczone były na zbiorze treningowym korzystając z krosvalidacji):

- średnia dokładność wybranego modelu: **0.823**
- najlepsza średnia dokładność po przycinaniu: **0.834**
- odchylenie standardowe dokładności wybranego modelu: **0.00414**
- odchylenie standardowe dokładności po przycinaniu (dla najlepszej średniej): **0.00659**


Widać zatem, że wyniki są zbliżone, co świadczy o dobrym wyborze modelu na podstawie danych parametrów.

3 Cechy optymalnego modelu

Model z możliwie najlepiej dobranymi parametrami został sprawdzony na zbiorze testowym. Jego własności predykcyjne wyglądają następująco:

1. Macierz pomyłek: $\begin{bmatrix} 2430 & 528 \\ 552 & 2490 \end{bmatrix}$
2. Dokładność (*accuracy*): **0.820**
3. Czulość (*recall*): **0.818**
4. Precyzja (*precision*): **0.825**
5. Krzywa ROC i wartość AUC (w prawym dolnym rogu wykresu):

Rysunek 2: Wykres krzywej ROC



4 Podsumowanie

Dokładności na zbiorze testowym i treningowym wybranego modelu są bardzo zbliżone oraz wartość AUC jest wysoka, co pokazuje że istotnie model ten jest optymalny względem danych parametrów.